

针对评论文本的情感分析方法

杨玉娟¹, 袁欢欢², 王永利²

(1.南京图书馆, 江苏 南京 210018; 2.南京理工大学 计算机科学与工程学院, 江苏 南京 210094)

摘 要: 为了克服传统基于机器学习的情感分析算法依赖手工建立情感词典、需要进行人工干预的缺点, 该文提出 1 种加权 word2vec 注意力长短记忆网络(WWAL) 情感分析模型。突出评论文本中关键词的作用, 在 word2vec 的基础上引入了术语频率-逆文档频率(TFIDF) 算法形成词向量, 同时在长期短期记忆(LSTM) 网络模型中加入了注意力机制。在标准数据集上的实验证明, 该文 WWAL 模型的查准率、召回率和 F_1 指标等实验衡量指标均优于传统机器学习方法。
关键词: 评论文本; 情感分析; 术语频率-逆文档频率; 长期短期记忆; 注意力
中图分类号: TP391 **文章编号:** 1005-9830(2019) 03-0280-06
DOI: 10.14177/j.cnki.32-1397n.2019.43.03.005

Sentiment analysis method for comment text

Yang Yujuan¹, Yuan Huanhuan², Wang Yongli²

(1.Nanjing Library, Nanjing 210018, China; 2.School of Computer Science and Engineering, Nanjing University of Science and Technology, Nanjing 210094, China)

Abstract: A weighted word2vec-attention long short-term memory(WWAL) emotion analysis model is proposed to overcome the shortcomings of traditional machine learning-based sentiment analysis algorithms of relying on manual establishment of emotional dictionary and manual intervention. The role of keywords in the comment text is highlighted. Word vectors based on word2vec are formed by introducing the term frequency-inverse document frequency(TFIDF) algorithm. An attention mechanism is introduced in the long short-term memory(LSTM) networks model. Experimental results on the standard dataset show the WWAL model is better than the traditional machine learning method in

收稿日期: 2018-08-16 修回日期: 2018-12-14

基金项目: 国家自然科学基金(61170035; 61272420; 81674099; 61502233); 中央高校基本科研业务费专项资金(30918012204; 30918015103); 南京市科技计划项目(201805036); “十三五”装备领域基金(61403120501)

作者简介: 杨玉娟(1981-), 女, 副研究馆员, 主要研究方向: 情报检索、自然语言处理等, E-mail: njlib_yang@126.com; 通讯作者: 王永利(1974-), 男, 博士, 教授, 主要研究方向: 海量数据分析、自然语言处理等, E-mail: yongliwang@njut.edu.cn。

引文格式: 杨玉娟, 袁欢欢, 王永利. 针对评论文本的情感分析方法[J]. 南京理工大学学报, 2019, 43(3): 280-285.

投稿网址: <http://zrxuebao.njust.edu.cn>

terms of precision, recall and F_1 indicators.

Key words: comment text; sentiment analysis; term frequency-inverse document frequency; long short-term memory; attention

文本情感分析的主要目的是识别用户在评论文本中表达的情感信息,从这些信息中了解人们对于某些事物的偏好或者是对于某些社会现象的观点。广义上情感主要分为正面情绪和负面情绪 2 类。常见的情感分析方法有:基于情感词典的无监督分类方法,计算待测文本中正负情感词的相对数量,由此来决定文本的情感倾向;基于机器学习的有监督分类方法,将已标注的语料作为模型的训练输入,通过特征函数选取最具有区分性的特征,再使用机器学习的算法训练语料库得到分类模型,最后进行情感分类。目前文本情感分析的主流方法是基于机器学习的有监督分类方法。为了克服传统机器学习存在的缺陷,比如:计算量较小、复杂函数的表达能力有限等,人们通过引入情感词典、句法规则等人工构造特征来提高文本情感分析的查准率。但是,人工构造特征需要耗费时间和精力,还会出现一些无法避免的微小误差。随着网络规模的迅速扩大,评论文本的数量骤然增多,里面包含的信息也越来越复杂,使得人工构造特征受到了极大的限制。

最近 2 年,深度学习技术得到了迅速发展^[1],人们发现基于深度学习相关技术对文本中的情感进行分析比传统学习方法的效果更好^[2]。采用深度学习方法,不需要依赖任何人工标注的情感词典以及句法分析结果,建立好神经网络就可以直接进行情感分类。但是很多神经网络模型忽略了关键词的作用。注意力机制能够在文本和图像领域获得优异结果,如图像识别^[3]、机器翻译^[4]、语义蕴含^[5]和句子总结^[6]。更重要的是,注意力机制可以提高阅读综合能力^[7]。

本文提出了加权 word2vec 注意力长短记忆(Weighted word2vec-attention long short-term memory, WWAL)网络情感分析模型。首先对输入的评论文本进行预处理,利用 word2vec 为每个单词构建向量,通过术语频率-逆文档频率(Term frequency inverse document frequency, TFIDF)算法为每个词向量分配 1 个权重,形成长期短期记忆(Long short-term memory, LSTM)的输入;在 LSTM 网络模型基础上加入注意力(Attention)机制进行

文本情感分析,突出评论文本中关键词的作用。

1 相关工作

1.1 词向量表示

独热表示(One hot representation)方法中对应于目标字的元素不为 0,所有其他元素都是 0。所以 One hot representation 存在维度灾难和“词汇鸿沟”现象,即任意 2 个词之间都是孤立的。分布式表示(Distributed representation)解决了 One hot representation 的问题,在训练过程中将每个词都映射到 1 个较短的词向量上来。但是这个较短的词向量的维度一般需要在训练时人为指定。

word2vec 出现之前,已经有人用神经网络来训练词向量。Bengio^[8]第 1 次使用 3 层神经网络构建语言模型,但是,因为词汇表一般在百万级以上,所以模型的处理过程非常耗时,这意味着模型的输出层计算各个词的输出概率的计算量非常大。文献[9]使用层析对数双线性(Log-bilinear)模型训练语言模型。Mikolov^[10]提出的 Log-bilinear 模型最大的特点是摒弃了传统神经网络的隐藏层,利用其线性表示能力计算词语的实数,用来表示词向量,优化了之前的 Log-bilinear 模型。

传统的文本表示方法存在高维、稀疏且未含有语义信息的缺点,本文使用 word2vec 工具表示向量。word2vec 通过神经网络机器学习算法训练 N 元(N-gram)语言模型,并在训练过程中求出单词所对应的向量。相比之前文本表示方法生成的向量,word2vec 模型生成的向量不仅维度较低而且携带了上下文的语义信息。但 word2vec 模型本身无法计算出文本中词汇的重要度,因此本文通过 TFIDF 算法给 word2vec 词向量进行加权。

1.2 文本情感分析

文本情感分析的研究方法分为 2 大类。一类是基于手工建立的情感词典及句法规则的方法。文献[11]通过情感词典及词性求出文本中

情感词的得分,并将其按特定规则组合计算,来判断文本的情感倾向性。文献[12]利用不同领域情感表达方式的共同特性来构建领域相关的情感词典,扩充文本特征,从而提高了跨领域情感分类的效果。文献[13]使用标签传播算法构建了覆盖领域语境的中文情感词典,利用构建好的词典进行文本情感分析。文献[14]在中文情感词典的基础上,考虑了评论文本中出现的表情,来计算文本的语义相似度和倾向性。但是基于情感词典与句法规则的方法不具有普遍性,每个领域都需要建立对应的情感词典,并且情感词典和规则需要人工设计,存在一定的误差。

另一类是基于机器学习的方法,也是目前研究使用较多的。在基于传统机器学习的情感分析研究中,人工设计特征和构建情感字典具有很强的随机性,不具备通用性,需要耗费较长的时间。然而,深度学习技术可以利用深度神经网络模型自动地学习文本的深层特征,尤其是递归神经网络(Recurrent neural network, RNN)模型的出现,更加推动了文本情感分析的发展,该模型可以很好地学习文本这类序列化数据的深层特征。文献[15]采用递归神经网络和情感极性转移模型对中文微博进行情感分析。文献[16]利用 word2vec 模型训练得到文本的词向量,利用卷积神经网络实现情感分类。

针对文本特征选择问题的梯度消失问题,本文提出的 WWAL 模型通过 LSTM 模型门控制机制,解决了 RNN 模型训练中的长期依赖问题。同时本文在 LSTM 模型的基础上加入 Attention 机制,减小了在特征向量提取过程中忽略重要信息或者添加不必要信息的可能性,能够有效地突出文本中关键词的作用。

2 WWAL 情感分析模型

2.1 模型框架

WWAL 情感分析模型流程如图 1 所示。首先对输入的评论文本进行预处理,利用 word2vec 为每个单词构建向量,通过 TFIDF 算法为每个词向量分配 1 个权重,形成 LSTM 的输入;然后利用加入 Attention 机制的 LSTM 网络训练特征向量,使得输出的特征向量包含词语义特征和单词序列特征;最后在输出层使用 Softmax 回归分类器来

预测文本的情感取向。

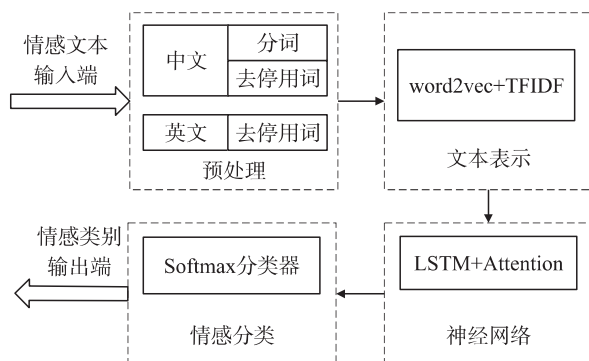


图 1 WWAL 情感分析模型框架图

2.2 加权 word2vec

word2vec 模型根据数据集中的每个句子进行训练,并且以 1 个固定窗口在句子上进行滑动,根据句子的上下文预测固定窗口中间的词的向量,然后根据 1 个损失函数和优化方法对模型进行训练。相比于其他文本表示方法,word2vec 模型生成的词向量包含了上下文的语义信息。然而 word2vec 模型无法识别文本中哪些词汇相对比较重要,TFIDF 算法可以计算特征项的权重值。TFIDF 综合考虑了每个词在单个文档中出现的概率 f 以及该词在整个文档集中的权重 q 。因此,本文基于 TFIDF 算法提出了加权 word2vec 模型。

评论文本集合 D 包含了 M 个评论文本,假设文本 $D_i (i=1, 2, \dots, M)$ 已分好词,将分好词的文本通过 word2vec 模型进行训练,生成每个单词对应的 N 维词向量 $w = [v_1 \ v_2 \ \dots \ v_N]$ 。利用 TFIDF 算法计算词 t 在文本 $D_i (i=1, 2, \dots, M)$ 中的权重值 $K(t, D_i)$ 。词 t 的 f 和 q 计算公式如下

$$\begin{aligned} f(t, D_i) &= \frac{n_t}{n_{D_i}} \\ q(t) &= \log\left(\frac{M}{n_t} + 0.01\right) \end{aligned} \quad (1)$$

式中: n_t 表示词 t 在文本 $D_i (i=1, 2, \dots, M)$ 中出现的次数, n_{D_i} 表示文本 D_i 中所有词的总数。 M 为训练文本的总数, n_t 为训练文本集中出现词 t 的文本数。权重值

$$K(t, D_i) = \frac{f(t, D_i) \times q(t)}{\sqrt{\sum_{t \in D_i} [f(t, D_i) \times q(t)]^2}} \quad (2)$$

式中: $f(t, D_i)$ 为词 t 在第 i 个评论文本中的词频。对于每个文本 D_i , 其文本向量

$$x_i = \sum_{t \in D_i} w_t K(t, D_i) \quad (3)$$

式中: w_t 表示词 t 的词向量。

2.3 基于注意力机制的 LSTM

LSTM 模型由 3 个门即输入门(input gate) i 、输出门(output gate) o 和遗忘门(forget gate) f 以及 1 个细胞记忆状态 c 组成。网络的输入、输出和细胞(cell) 单元的状态由 3 个控制门控制, 这 3 个门的输出分别连接到 1 个乘法单元上。利用数学语言 LSTM 模型表达式

$$\begin{aligned} i_t &= \delta(W_i x_t + U_i h_{t-1} + V_i c_{t-1} + b_i) \\ f_t &= \delta(W_f x_t + U_f h_{t-1} + V_f c_{t-1} + b_f) \\ c_t &= f_t \cdot c_{t-1} + i_t \cdot \tanh(W_c x_t + U_c h_{t-1} + V_c c_{t-1} + b_c) \\ o_t &= \delta(W_o x_t + U_o h_{t-1} + V_o c_{t-1} + b_o) \\ h_t &= o_t \cdot \tanh(c_t) \end{aligned} \quad (4)$$

式中: i_t 、 f_t 、 o_t 分别表示 t 时刻 input gate、forget gate 和 output gate 的计算公式, c_t 表示 t 时刻记忆单元的计算公式, h_t 为 t 时刻 LSTM 单元的输出。其中 δ 为激活函数, W 、 U 、 V 为系数矩阵, b 为偏置向量。

原始的编解码器模型结构根据时间步模型设计, 所有的上下文输入信息都被限制到固定长度, 整个模型的能力都同样受到限制。为了解决这一缺陷, 引入了 Attention 机制。Attention 机制分为 2 种类型: 基于内容(Content-based) 和基于位置(Location-based)。本文结合了文本情感分析的特性在 LSTM 模型基础上引入 Content-based 的注意力机制, 形成 Att-LSTM 模型。

Attention 机制负责给输入的上下文信息打分, 反映了编码器输入注意力位置与解码器输出注意力权重之间的关系。基于 Attention 机制的 LSTM 模型保留了 LSTM 编码器对输入序列的中间输出结果, 通过训练 1 个模型对这些中间输出结果进行选择学习, 并且在模型输出时将输出序列与之进行关联。Attention 机制解决了传统编解码器结构在处理时依赖于内部 1 个固定长度向量的限制。

如图 2 所示, 该模型有 2 个输入部分, 一部分是加权 word2vec 形成的文本表示序列 $X = \{x_1, x_2, \dots, x_T\}$, 另一部分是文章总体的输入向量 X' 即最后输入节点 K 表示的向量, 将历史节点的输入向量的累加值求平均值可以得到。 h_1, h_2, \dots, h_T 是文本输入序列 x_1, x_2, \dots, x_T 的隐藏层状态值。 H_k 表示输入向量 X' 的隐藏层状态值。 a_{ki} 是历史节点相对于最后节点的注意力概率。

基于注意力机制的 LSTM 模型计算注意力概

率分布后, 生成了包含注意力概率分布的语义编码, 形成最终的特征向量。

(1) 计算注意力分布概率

$$a_{ki} = \frac{\exp(e_{ki})}{\sum_{i=1}^T \exp(e_{ki})} \quad e_{ki} = v \tanh(W H_k + U h_i + b) \quad (5)$$

式中: T 表示输入序列包含的元素数目, H_k 表示 X 输出的隐藏层状态, h_i 表示输入序列中第 i 个元素对应的隐藏层状态, a_{ki} 表示节点 i 相对于节点 K 的注意力概率权重。

(2) 计算注意力分布概率的语义编码和特征向量

$$C = \sum_{i=1}^T a_{ki} h_i \quad H_k^* = H(C H_k X) \quad (6)$$

节点注意力概率权重与节点隐藏层状态乘积进行累加可以得到语义编码 C 。 H_k^* 表示分类器最终需要输入识别的特征向量, H_k^* 特征向量不仅包含了最后节点的特征信息, 同时还包含了历史输入节点的权重信息。基于 Attention 机制的 LSTM 模型充分发挥了输入历史节点中关键节点语义信息的作用。最后利用 Softmax 层进行归一化, 变换成条件概率分布。其中, W_s 和 b_s 是 Softmax 层的参数。

$$s(x) = \text{Softmax}(W_s H_k^* + b_s) \quad (7)$$

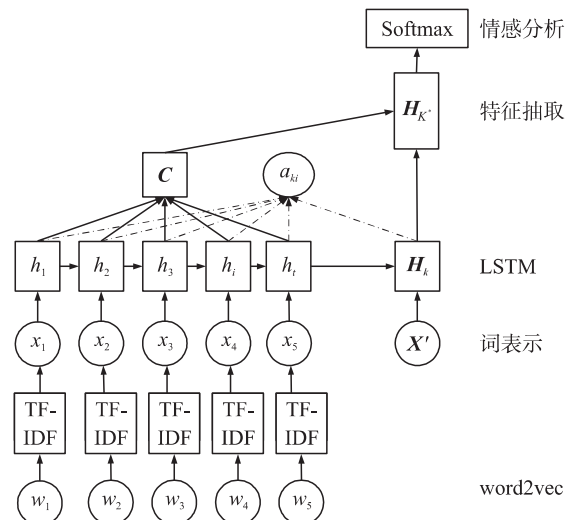


图 2 基于注意力机制的 LSTM 模型体系结构图

2.4 模型训练

WWAL 模型采用深度学习中的 Adam^[17] 优化算法进行模型训练。该算法是 1 种可以代替传

统随机梯度下降的一阶优化算法,它能基于训练数据迭代更新神经网络的权重。随机梯度下降算法使用单一的学习率更新所有的权重,在训练过程中学习率不变。Adam 算法通过计算梯度的一阶矩估计和二阶矩估计,为不同的参数设计独立的自适应性学习率。

Adam 算法

Input: θ

Parameter:

Step length $\varepsilon = 0.001$

Exponential decay rate of moment estimation $\rho_1 = 0.9$ $\rho_2 = 0.999$

Small constants for numerical stability $\delta = 10^{-8}$

Step:

Initialize first-order and second-order moment variables $s = 0$, $r = 0$

Initialize time step $t = 0$

While(Failed to meet stop condition) do

Take a small batch containing m samples $\{x^{(1)}, \dots, x^{(m)}\}$ from the training set and the corresponding target is $y^{(i)}$

Calculate the gradient $g \leftarrow \frac{1}{m} \nabla_{\theta} \sum_i L(f(x^{(i)}; \theta); y^{(i)})$

$t = t + 1$

Update first moment estimation: $s \leftarrow \rho_1 s + (1 - \rho_1) g$

Update second moment estimation: $r \leftarrow \rho_2 r + (1 - \rho_2) g \odot g$

Correct the deviation of the first moment: $s' \leftarrow \frac{s}{1 - \rho_1^t}$

Correct the deviation of the second moment: $r' \leftarrow \frac{r}{1 - \rho_2^t}$

Calculate update value: $\Delta \theta = -\varepsilon \frac{s'}{\sqrt{r'} + \delta}$

Apply update value: $\theta \leftarrow \theta + \Delta \theta$

End while

3 实验及分析

本文数据集为 2 部分,英文数据集和中文数据集。英文数据集为 IMDB(Internet movie database)影评集。IMDB 数据集包含 25000 条电影数据,正负类各 12 500 条。中文数据集选取的是 ChnSentiCorp,该数据集是由中科院谭松波博士收集整理的关于酒店评论的语料库。本文选用 ChnSentiCorp-Htl-ba-6000 进行实验,正负类各 3 000 条。中文文本相对于英文文本,需要进行分词操作。

一般情况下,机器学习的性能通常由查准率(p)和召回率(r)2 种指标进行评价。查准率针对文本情感预测结果,表示正确预测为正类的文本占全部预测为正类的文本比例。而召回率是针对样本,即正确预测为正类的文本占全部实际为正类的文本比例。

$$p = \frac{T_p}{T_p + F_p} \quad (10)$$

$$r = \frac{T_p}{T_p + F_N} \quad (11)$$

式中: T_p (True positive) 表示文本情感为正类,模型预测为正类情感的数量; F_N (False negative) 表示文本情感为正类,模型预测为负类情感的数量; F_p (False positive) 表示文本情感为负类,模型预测为正类情感的数量。查准率和召回率需要同时考虑,缺一不可,引入 F_1 测度作为第 3 个指标,均衡上述 2 个指标

$$F_1 = \frac{2 \times p \times r}{p + r} \quad (12)$$

3.1 对比算法

本文方法与基于 word2vec 的支持向量机(Support vector machine, SVM)方法、基于 word2vec 的 LSTM 方法、基于加权 word2vec 的 LSTM 方法以及基于 Attention 机制的 LSTM 方法针对上述的查准率、召回率和 F_1 指标进行对比实验。W2V-SVM 模型将待测文本利用 word2vec 转换为向量后,通过 SVM 模型训练分类。W2V-NN 模型将待测文本利用 word2vec 转换为向量后,通过普通的神经网络进行分类。W2V-LSTM 模型将待测文本利用 word2vec 转换为向量后,通过 LSTM 模型训练分类。加权 W2V-LSTM 模型结合 TFIDF 算法和 word2vec 将待测文本转化为向量,通过 LSTM 训练分类。W2V-Att-LSTM 模型将待测文本利用 word2vec 训练转换为向量后,利用基于 Attention 机制的 LSTM 模型进行训练。加权 W2V-Att-LSTM 模型结合 TFIDF 算法和 word2vec 将待测文本转化为向量,将待测文本利用 word2vec 训练转换为词向量以后,利用基于 Attention 机制的 LSTM 模型进行训练。

3.2 参数设置

(1) 实验环境配置。开发语言为 Python,模型框架为 TensorFlow 框架。操作平台为 Win10,采用 Intel 双核 4.0 GHz CPU、12G 内存、1T 硬盘。

(2) LSTM 模型超参数定义。批处理大小

batchsize 为 24 ,LSTM 的单元个数 lstmUnits 为 64 ,分类类别 numClass 为 2 ,训练次数 iteration 为 100 000 ,优化器选择了常用的 Adam ,学习率默认设置为 0.001。

从表 1 对比实验的性能结果可以看出 ,本文提出的模型非查准率、召回率和 F_1 测度 3 个指标的效果均要好于其他模型。从表 1 中不难发现 ,模型在英文数据集上的效果要远远好于在中文数

据集上的效果 ,主要是因为中文在预处理阶段需要进行分词操作 ,分词总会不可避免地出现一些微小误差。分词造成的语义偏差会降低模型的性能。对比算法中加权 W2V-LSTM 的效果没有 W2V-Att-LSTM 好 ,说明对于文本情感分析 ,计算词的重要程度时 TFIDF 算法没有 Attention 机制表现好 ,因为基于 TFIDF 算法获得的词是与最终目标相关的关键词。

表 1 对比实验性能结果表

算法	英文			中文		
	p	r	F_1	p	r	F_1
W2V-SVM	0.9111	0.9119	0.9124	0.8125	0.8119	0.8121
W2V-NN	0.9239	0.9301	0.9225	0.8391	0.8339	0.8365
W2V-LSTM	0.9426	0.9506	0.9507	0.8516	0.8496	0.8501
Weighted W2V-LSTM	0.9631	0.9527	0.9603	0.8613	0.8543	0.8671
W2V-Att-LSTM	0.9669	0.9675	0.9682	0.8693	0.8615	0.8771
Weighted W2V-Att-LSTM	0.9739	0.9613	0.9715	0.8727	0.8713	0.8719

4 结束语

本文提出了 WWAL 文本情感分析方法 ,通过 word2vec 模型将文本训练为词向量后 ,结合 TFIDF 算法加入权重矩阵 ,形成 LSTM 的输入。通过 LSTM 得到文本相关特征 ,再结合 Attention 机制 ,得到特征向量 ,实现情感分类。实验结果表明了本文方法比传统方法更加有效 ,可以更好地判断文本的情感倾向性。目前评论信息中英文混合的信息越来越多 ,后续工作将进一步探讨中英文混合文本的情感分析任务。

参考文献:

- [1] 缪弘 张文强. 基于深度卷积神经网络的视觉 SLAM 去模糊系统 [J]. 中兴通讯技术 ,2018 ,24 (5) : 62-66.
Miao Hong , Zhang Wenqiang. Deep convolutional neural network for visual SLAM deblurring [J]. ZTE Technology Journal 2018 24(5) : 62-66.
- [2] Li Minjia , Xie Lun , Wang Zhiliang , et al. Emotion and cognitive reappraisal based on GSR wearable sensor [J]. ZTE Communications 2017 ,15(S2) : 18-22.
- [3] Mnih V , Heess N , Graves A , et al. Recurrent models of visual attention [J]. Advances in Neural Information Processing Systems 2014 ,3(6) : 2204-2212.

- [4] Bahdanau D , Cho K , Bengio Y. Neural machine translation by jointly learning to align and translate [DB/OL]. <https://arxiv.org/pdf/1409.0473> ,2019-05-07.
- [5] Rocktäschel T , Grefenstette E , Hermann K M , et al. Reasoning about entailment with neural attention [DB/OL]. <https://arxiv.org/pdf/1509.06664> ,2019-05-07.
- [6] Rush A M , Chopra S , Weston J. A neural attention model for abstractive sentence summarization [DB/OL]. <https://arxiv.org/pdf/1509.00685> ,2019-05-07.
- [7] Hermann K M , Kočiský T , Grefenstette E , et al. Teaching machines to read and comprehend [DB/OL]. <https://arxiv.org/pdf/1506.03340.pdf> ,2019-05-07.
- [8] Bengio Y , Ducharme R , Vincent P. A neural probabilistic language model [J]. Journal of Machine Learning Research 2003 ,3(2) : 1137-1155.
- [9] Mnih A , Hinton G E. A scalable hierarchical distributed language model [C]//Proceeding NIPS'08 Proceedings of the 21st International Conference on Neural Information Processing Systems. Vancouver Canada: Curran Associates Inc. ,2009: 1081-1088.
- [10] Mikolov T , Chen K , Corrado G , et al. Efficient estimation of word representations in vector space [DB/OL]. <https://arxiv.org/pdf/1301.3781.pdf> ,2019-05-07.

(下转第 291 页)

- [23] Chen Huaijun ,Shi Lanfang ,Mo Jiaqi. The generalized interior shock layer solution of nonlinear singularly perturbed equation[J]. J Univ Sci Tech China ,2015 , 15(8) : 639-643.
- [24] Xu Jianzhong ,Zhou Zongfu. Existence and uniqueness of anti-periodic solutions for a kind of nonlinear n th-order differential equation with multiple deviating arguments [J]. Ann Diff Eqn 2012 28(1) : 105-114.
- [25] Xu Jianzhong ,Zhou Zongfu. Anti-periodic solutions for a kind of nonlinear n th-order differential equation with multiple deviating arguments [J]. J Chongqing Technology and Business Univ 2010 6: 545-550.
- [26] 徐建中 ,周宗福. 一类具有多个变参数的中立型泛函微分方程的反周期解的存在性[J]. 合肥学院学报 2011 21(4) : 7-11 36.
Xu Jianzhong ,Zhou Zongfu. The existence of anti-periodic solutions for a p -Laplacian neutral functional differential equation with multiple variable parameters [J]. J Hefei Univ 2011 21(4) : 7-11 36.
- [27] 徐建中 ,周宗福. 一类四阶具有多个偏差变元 p -Laplacian 中立型微分方程周期解的存在性 [J]. 重庆工商大学学报 2012 29(11) : 9-16.
- Xu Jianzhong ,Zhou Zongfu. The existence of periodic solutions for a class of fourth-order p -Laplacian neutral functional differential equation with multiple deviating arguments [J]. J Chongqing Technology and Business Univ 2012 29(11) : 9-16.
- [28] 徐建中 ,周宗福. 一类具有多个偏差变元高阶微分方程反周期解的存在唯一性 [J]. 重庆工商大学学报 2017 34(2) : 1-5.
Xu Jianzhong ,Zhou Zongfu. Existence and uniqueness of anti-periodic solutions for a class of high-order differential equation with multiple deviating arguments [J]. J Chongqing Technology and Business Univ , 2017 34(2) : 1-5.
- [29] He Jihua ,Wu G C ,Austin F. The variational iteration method which should be followed [J]. Nonlinear Sci Lett A 2010 1(1) : 1-30.
- [30] 何吉欢. 工程和科学计算中的近似非线性分析方法 [M]. 郑州: 河南科学技术出版社 2002.
- [31] He Jihua ,Wu Xianhua. Construction of solitary solution and compacton-like solution by variational iteration method [J]. Chaos Solitions & Fractals 2006 , 29(1) : 108-113.

(上接第 285 页)

- [11] Taboada M ,Brooke J ,Tofiloski M. Lexicon-based methods for sentiment analysis [J]. Computational Linguistics 2011 37(2) : 267-307.
- [12] Bollegala D ,Weir D ,Carroll J. Using multiple sources to construct a sentiment sensitive thesaurus for cross-domain sentiment classification [C]//Meeting of the Association for Computational Linguistics: Human Language Technologies. Portland ,USA: Association for Computational Linguistics 2011: 132-141.
- [13] 李寿山 ,李逸薇 ,黄居仁 ,等. 基于双语信息和标签传播算法的中文情感词典构建方法 [J]. 中文信息学报 2013 27(6) : 75-82.
Li Shoushan ,Li Yiwei ,Huang Juren ,et al. Chinese emotional dictionary construction method based on bilingual information and label propagation algorithm [J]. Journal of Chinese Information Processing 2013 , 27(6) : 75-82.
- [14] 王文 ,王树锋 ,李洪华. 基于文本语义和表情倾向的微博情感分析方法 [J]. 南京理工大学学报 2014 , 38(6) : 733-738.
Wang Wen ,Wang Shufeng ,Li Honghua. A method of Weibo emotion analysis based on text semantics and expression tendency [J]. Journal of Nanjing University of Science and Technology 2014 38(6) : 733-738.
- [15] 梁军 ,柴玉梅 ,原慧斌 ,等. 基于深度学习的微博情感分析 [J]. 中文信息学报 2014 28(5) : 155-161.
Liang Jun ,Chai Yumei ,Yuan Huibin ,et al. Sentiment analysis of Weibo based on deep learning [J]. Journal of Chinese Information Processing ,2014 , 28 (5) : 155-161.
- [16] Kim Y. Convolutional neural networks for sentence classification [C]//Conference on Empirical Methods in Natural Language Processing (EMNLP 2014) . Doha ,Qatar: Association for Computational Linguistics , 2014: 1746-1751.
- [17] Kingma D P ,Ba J. Adam: A method for stochastic optimization [DB/OL]. <https://arxiv.org/pdf/1412.6980v8.pdf> 2019-05-07.